

基于 DDNet 和多维地质结构学习数据生成的地震降噪方法

桑文镜^{*①} 雍学善^② 焦新奇^① 袁三一^① 王尚旭^①

(^①中国石油大学(北京), 北京; ^②中国石油天然气股份有限公司勘探开发研究院西北分院, 甘肃兰州)

摘要 目前去噪卷积神经网络(denoising convolutional neural networks, DnCNNs)被广泛应用于去除含噪地震数据的随机噪声,但是 DnCNNs 很少考虑学习和保护不同维度的地质结构。针对这一问题,本文提出了一种基于改进的深度去噪网络(deep denoising networks, DDNet)和多方向地质结构学习数据生成的地震噪声压制方法。沿着三维合成地震数据的三个方向(即两个空间方向和一个时间方向)提取地震振幅数据,来准备训练数据集和验证数据集训练一个优化的网络去噪器。和所有的训练数据只来自同一个方向相比,这种数据生成策略使得 DDNet 从三个不同角度学习丰富的多维地质结构信息而提高 DDNet 的去噪性能。通过对含有丰富断层和河道结构的合成地震数据和陆地实际数据进行优化网络去噪器的直接推广去噪应用,结果表明学习多维地质结构的 DDNet 能自适应减小地震随机噪声,同时保护空间地质结构。

关键词 卷积神经网络 地震数据 去噪 地质结构 深度学习

1 引言

地震勘探是分析和理解地下地质构造和油气分布的重要手段。受多种复杂的地上及近地表条件影响,野外采集的地震数据往往受到噪声的污染,这必然影响地震资料的处理、解释和反演。近几十年来,大量的地震噪声压制方法被提出,如 f-x 反褶积^[1]、奇异值分解^[2]、曲波变换^[3]和基于反演的去噪方法^[4]。尽管这些方法利用有效信号和噪声在时间域、空间域、频率域、时空域、时频域或变换域的不同特征实现信噪分离,但是它们通常基于一定的数学假设。此外,大多数传统去噪方法不能自适应地应用于含复杂地质结构的地震数据。

随着机器学习算法在地震勘探领域的逐步应用,越来越多的学者开始使用 Zhang 等^[5]提出的去噪卷积神经网络(denoising convolutional neural networks, DnCNNs)压制地震随机噪声^[6]。但是作为一种数据驱动的算法,DnCNNs 的泛化性受到训练集中数据结构多样性和噪声水平等限制。目前,普遍采用的 2D 地震样本没有充分利用 3D 地震数据体中不同时空方向地质结构的差异性。另外,使用现有的模型驱动去噪方法从实际数据中估计近似干净数据和近似噪声数据增广时,近似噪声可能含有有效信号,可能导致机器学习系统学到错误信息。

本文提出一种基于端到端的深度去噪网络(deep denoising networks, DDNet)和多维地质结构学习数据生成的地震随机噪声去除方法。从 3D 合成地震数据的三个方向(即两个空间方向和一个时间方向)生成的大量训练数据使得 DDNet 可以从三个不同侧面学习多维地质结构。和所有训练样本来自同一方向相比,结合不同方向的训练样本使得 DDNet 去噪能力显著提高。不经过迁移学习和后处理,通过对含有丰富断层和发育河道的 3D 合成地震数据和 3D 陆地实际数据进行优化网络的直接推广去噪应用,去噪结果也表明这种方法在压制噪声的同时可以较好地保持不同的地质结构。

2 基于 DDNet 的地震去噪原理

地震数据去噪是从含噪地震数据 \mathbf{d} 中去除噪声 \mathbf{n} ,恢复重建出干净地震数据 \mathbf{s} 。它们的关系可以表述为:

$$\mathbf{d} = \mathbf{s} + \mathbf{n} \quad (1)$$

式中 \mathbf{n} 是随机噪声。如图 1 所示,为实现自动地震随机噪声去除,在 DnCNNs 的基础上修改得到网络深度设置为 27 的 DDNet。网络的输入和输出分别是含噪地震数据 \mathbf{d} 和随机噪声 \mathbf{n} 。隐层包括三种模块:(1)卷积层(Conv)+ReLU 激活;(2)卷积层+

批归一化层(BN)+ReLU 激活; (3)卷积层。前两类模块中每个卷积层有 64 个 3×3 卷积核, 最后一个模块只设置 1 个 3×3 卷积核。沿袭 DnCNNs 图像去噪思路, 本文直接建立含噪数据到残差噪声的非线性映射, 即:

$$R(\mathbf{d}; \boldsymbol{\theta}) = \mathbf{n}, \quad (2)$$

式中 $R(\mathbf{d}; \boldsymbol{\theta})$ 是从 \mathbf{d} 中学习出的噪声。含噪数据与预测噪声作差即得到学习的干净数据 $\mathbf{d} - R(\mathbf{d}; \boldsymbol{\theta})$ 。通常, 使用平均均方误差作为目标函数, 即:

$$l(\boldsymbol{\theta}) = \frac{1}{2N} \sum_{i=1}^N \|R(\mathbf{d}_i; \boldsymbol{\theta}) - (\mathbf{d}_i - \mathbf{s}_i)\|_F^2 \quad (3)$$

式中 $\{(\mathbf{d}_i, \mathbf{s}_i)\}_{i=1}^N$ 是 N 对含噪数据和干净数据样本, $\|\bullet\|_F = \sqrt{\sum (\bullet)^2}$ 是 Frobenius 范数。通过训练优化网络参数 $\boldsymbol{\theta}$, 损失函数 $l(\boldsymbol{\theta})$ 越小, 估计的地震信号越接近干净地震信号, 即:

$$\mathbf{d} - R(\mathbf{d}; \boldsymbol{\theta}) \approx \mathbf{s}, \quad (4)$$

本文采用信噪比(signal-to-noise ratio, SNR)衡量降噪能力, 其定义如下:

$$\text{SNR} = \frac{\|\mathbf{s}\|^2}{\|\mathbf{n} - R(\mathbf{d}; \boldsymbol{\theta})\|^2} \quad (5)$$




图 1 DDNet 网络结构图

3 多维地质结构学习数据生成

训练数据生成时, 首先准备 $32 \text{ 个 } 3.2 \text{ km}^2 \times 128 \text{ ms}$ 大小的 3D 合成地震数据, 其中一个如图 2(a)所示。并加入 30%(即噪声能量与信号能量的比值)的随机噪声生成含噪数据, 其中一个如图 2(b)所示。它们的时间采样间隔为 1ms, crossline 和 inline 方向的空间采样间隔为 25m。之后沿着 3D 合成地震数据的三个坐标轴方向分别提取 inline 剖面、crossline 剖面 and time 切片。接着利用步长为 10 的滑动窗裁剪剖面或切片得到大量的地震数据块, 并利用含噪和干净的 inline 数据块、crossline 数据块和 time 数据块分别制作三个数据集, 即 inline 数据

集、crossline 数据集和 time 数据集。为形成对比, 最后从上述三个数据集分别有序抽取 1/3 样本构成第四个数据集(即混合数据集)学习多维地质结构。学习到的去噪器可以近似看作单个方向学习的个体去噪器的集成。四个数据集分别含有 248832 对大小为 40×40 的含噪和干净数据。

4 网络训练

本文采用上述四个数据集和 DDNet 分别训练四个去噪器(即去噪器 1-4)。以训练第 4 个去噪器为例, 进入 DDNet 之前, 依据全部含噪数据计算尺度因子归一化每个数据到 $[0, 1]$ 。训练样本和验证样本分别为 240000 对、8832 对, 并设置批大小为 128, 学习率为 0.001, 自适应动量估计优化器 Adam 算法迭代更新网络参数^[7]。在 Keras 上训练 30 次 epoch 后, 训练误差和验证误差稳定地收敛到极小值。因此, 已经获得优化的网络模型。利用上述的尺度因子反归一化学到的干净数据即可得到去噪结果。

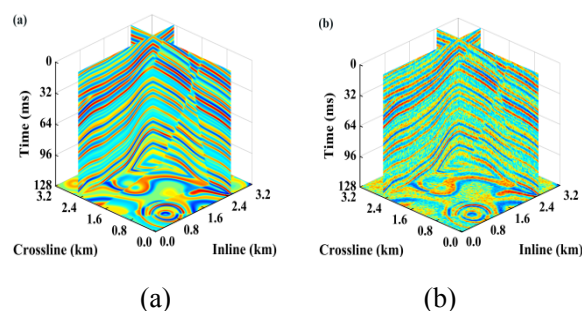


图 2 合成地震数据制作样本和标签

(a) 干净地震数据; (b) 含噪地震数据

5 数值算例

在测试阶段, 四个去噪器直接应用到图 3b 中 3D 含噪地震数据体, 该数据体是在 30Hz 雷克子波与 SEG/EAGE 推覆体模型褶积生成图 3a 对应的 3D 干净地震数据体的基础上, 加入 30%的随机噪声得到的。四个网络去噪器分别沿着 3D 数据体的 crossline、inline 和 time 方向的降噪结果如表 1 所示。可以看到混合数据集训练的去噪器沿着三个方向的降噪效果都明显优于其他三个去噪器, 去噪后地震记录的信噪比提高了约 50 倍。这表明使用来自三个不同方向的地震数据训练模型有助于提高网络去噪能力。

表 1 四个网络去噪器的降噪能力对比

去噪方向	去噪器 1	去噪器 2	去噪器 3	去噪器 4
Inline	40.92	35.47	84.65	113.75
Crossline	42.00	36.71	86.40	120.96
Time	24.50	21.55	109.82	153.24




图 3 3D 合成地震数据去噪测试

(a) 干净地震数据, (b) 含噪地震数据 (SNR=3.33dB), (c) 去噪结果 (SNR=153.24dB), (d) 预测的噪声。




图 4 振幅切片去噪测试

(a) 干净振幅切片, (b) 含噪振幅切片 (SNR=1.94dB), (c) 去噪结果 (SNR=85.72dB), (d) 预测的噪声。

图 3 展示的是表 1 中去噪器 4 沿 3D 地震数据时间方向降噪结果。从图 3c-d 可以看出去噪后地震数据和干净数据近似, 表明有效信号能量损失小, 噪声被几乎完全压制。为进一步说明学习多种地质结构的去噪器的去噪效果, 如图 4a-b, 展示 3D 干

净数据(图 3a)和 3D 含噪数据(图 3b)在 100ms 对应的沿层振幅切片。尽管从图 4b 重建被噪声严重淹没的河道充满挑战, 但是混合数据集训练得到的去噪器 4 仍清晰地恢复出两期河道系统, 并明显提高信噪比。

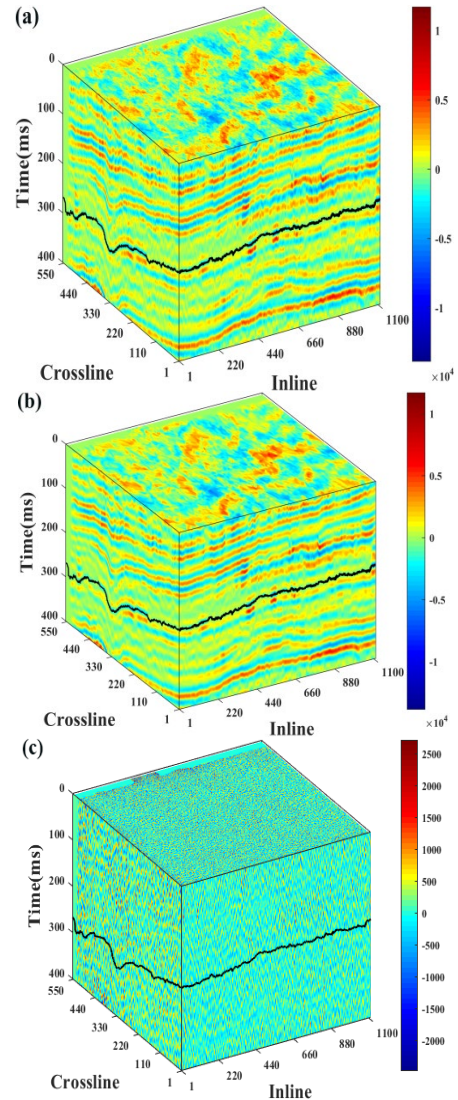


图 5 3D 实际地震数据去噪测试

(a) 3D 实际地震数据; (b) DDNet 去噪结果; (c) 预测的噪声。(a-c) 中的黑线代表解释的层位。

应用中国西北某地实际地震数据验证 DDNet 的有效性。该实际数据大小 $1112\text{Inlines} \times 556\text{Crosslines} \times 201\text{samples}$, 时间采样间隔 2ms, 沿着 crossline 方向(西-东)和 inline 方向(南-北)道间距 25m。对比去噪结果和预测的噪声(图 5b-c)可以看到, 去噪后水平的、线性的、弯曲的和连续的地震事件更加清晰和连续, 能量损失也较少。图 5a-b 中的黑色实线代表解释的层位, 图 6a-b 是沿着层位

提取的沿层振幅切片。观察图 6a-b 中的红色、黑色和蓝色虚线椭圆内的区域不难发现,红色和蓝色箭头附近的小断层去噪后更加干净连续,图 6b 黑色箭头附近河道的轮廓和边界显示得更加清晰。

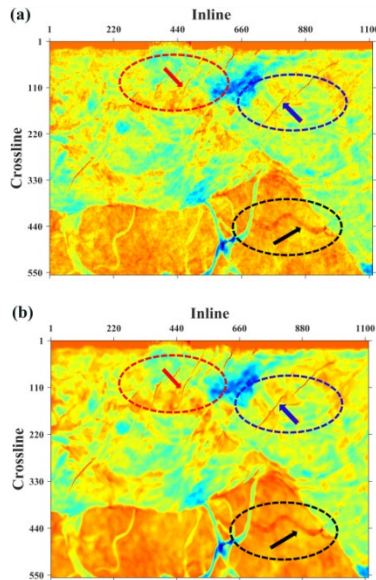


图 6 层位切片去噪测试

(a) 去噪前沿层振幅切片; (b) 去噪后沿层振幅切片去噪后(b)的椭圆内,尤其是箭头附近的地质体变得更加清晰和连续

6 结论

本文提出一种新的数据生成方法学习多种方向性的地质结构特征,解决 DnCNNs 难以推广到实际数据降噪的问题。通过提取 3D 合成地震数据不同方向的地震剖面 and 不同时间切片丰富训练样本,

并从三个不同方向实现多维地质结构学习。另一个 3D 合成数据集去噪测试表明从三个空间延伸方向学习地质结构有助于网络理解地质体的几何形态和空间展布。因此,学习丰富的合成地震数据集和标签集的优化去噪器可以直接用来对另一个 3D 合成地震数据和实际数据降噪,并同时保护包括断层和河道在内的地质结构。

致谢 感谢国家重点研发计划(2018YFA0702504)和国家自然科学基金(41674127)等的联合资助。

参考文献

- [1] Canales, L.L., Random noise reduction: 54th Annual International Meeting, SEG, Expanded Abstracts, 1984, 3(1):525-527.
- [2] Bekara, M., and Baan, M.V., Local singular value decomposition for signal enhancement of seismic data: Geophysics, 2007, 72(2):59-65.
- [3] Herrmann, F.J., Wang, D.L., Hennenfent, G., and Moghaddam, P.P., Curvelet-based seismic data processing: A multiscale and nonlinear approach: Geophysics, 2008, 73(1):A1-A5.
- [4] Yuan, S.Y., Wang, S.X., Luo, C.M., and Wang, T.Y., Inversion-based 3-D seismic denoising for exploring spatial edges and spatio-temporal signal redundancy: IEEE Geoscience and Remote Sensing Letters, 2018, 15(11):1682-1686.
- [5] Zhang, K., Zuo, W., Chen, Y., Meng, D., and Zhang, L., Beyond a gaussian denoiser: Residual learning of deep CNN for image denoising: IEEE Transactions on Image Processing, 2017, 26(7):3142-3155.
- [6] Yu, S.W., Ma, J.W., and Wang, W.L., 2019, Deep learning for denoising: Geophysics, 84(6):V333-V350.
- [7] Kingma, D.P., and Ba, J.L., 2015, Adam: A method for stochastic optimization: ICLR, 2015, 1-41.